




Deskripsi Data

Dr. Jasman Pardede, S.Si., MT.

Machine Learning Process



A Standard Machine Learning Pipeline




Steps

- Data Preparation
- Feature Extraction
- Create Model by Model Training
- Test Data
- Save Model
- Predictions



Tahapan Analisis Data

- Memutuskan tujuan analisis data (defining goal)
 - Mendapatkan data
 - Merapihkan data
 - Merepresentasikan data sebagai feature vector
 - Melakukan transformasi dan/atau feature selection (mengurangi dimensi feature vector)
 - Melatih model (training) dan menganalisa kinerjanya terhadap validation data (development)
 - Melakukan testing dan analisis model baik secara kuantitatif dan kualitatif.
 - Menyajikan data (presentasi)
- 



Tipe data pada ML

- Text (text data) → Amazon Reviews Dataset, Enron Email Dataset, Goodreads Book Reviews, WordNet
- Citra (image data) → Coco dataset, Imagenet, Baidu ApolloScape Dataset, Waymo Open Dataset
- Audio (audio data) → Environmental audio datasets, Speech commands dataset, Free music archive (FMA), Flickr audio caption corpus, Common voice
- Video (video data), OTB, ActivityNet, Kinetic, HMDB51
- Numerik (numeric data) → Google Dataset Search




Beberapa istilah yang sering pada dataset

- a. Instance:** Setiap baris data pada table disebut sebagai instance. *Instance* menunjukkan sebuah pengamatan dari domain permasalahan.
- b. Feature:** Setiap kolom pada table di sebut sebagai *feature*. *Feature* merupakan komponen dari pengamatan. Feature berisi input data (*predictors*) dan sebagian lagi adalah hasil prediksi (*ouput*)
- c. Dataset:** Kumpulan instance yang membentuk data set.
- d. Data Type:** tipe data yang ada pada tiap Feature.

Dataset pada ML ada 2

- Terstruktur
- Tidak terstruktur



Bagian dataset employee

First Name	Gender	Start Date	Last Login Time	Salary	Bonus %	Senior Management	Team
Douglas	Male	8/6/1993	12:42 PM	97308	6.945	TRUE	Marketing
Thomas	Male	3/31/1996	6:53 AM	61933	4.17	TRUE	Business Development
Maria	Female	4/23/1993	11:17 AM	130590	11.058	FALSE	Finance
Jerry	Male	3/4/2005	1:00 PM	138705	9.34	TRUE	Finance
Larry	Male	1/24/1998	4:47 PM	101004	1.389	TRUE	Client Services
Dennis	Male	4/18/1987	1:35 AM	115163	10.125	FALSE	Legal
Ruby	Female	8/17/1987	4:20 PM	65476	10.012	TRUE	Product

Feature

Instance

Contoh dataset berlabel


Atribut						Target/label
Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species	
48	4.6	3.2	1.4	0.2	Iris-setosa	
49	5.3	3.7	1.5	0.2	Iris-setosa	
50	5	3.3	1.4	0.2	Iris-setosa	
51	7	3.2	4.7	1.4	Iris-versicolor	
52	6.4	3.2	4.5	1.5	Iris-versicolor	
99	5.1	2.5	3	1.1	Iris-versicolor	
100	5.7	2.8	4.1	1.3	Iris-versicolor	
101	6.3	3.3	6	2.9	Iris-virginica	
102	5.8	2.7	5.1	1.9	Iris-virginica	
103	7.1	3	5.9	2.1	Iris-virginica	
104	6.3	2.9	5.6	1.8	Iris-virginica	

Contoh dataset tidak berlabel

Atribut


ID_Pelanggan	Gender	Usia	Pendapatan_Tahunan_Ribuan_USD	Pengeluaran_USD
1	Pria	19	15	39
2	Pria	21	15	81
3	Wanita	20	16	6
4	Wanita	23	16	77
5	Wanita	31	17	40
6	Wanita	22	17	76
7	Wanita	35	18	6

Tipe data pada machine learning





Tipe Data Kuantitatif pada Machine Learning

➤ Jenis Data diskrit



➤ Jenis Data kontinu




Contoh data Kualitatif - terstruktur

	ID	Nama	Umur	Strata	
	1	Jhon	18	B.Sc	
	2	David	29	Ph.D	
	3	Robert	19	B.Sc	
	4	Jesline	23	M.Sc	
	5	Jesella	30	Ph.D	

Contoh data terstruktur

➤ Data nominal:




➤ Data biner: {0, 1}


➤ Data ordinal:



➤ Data interval



➤ Data rasio



Contoh data semi-terstruktur

- Json
- xml

```
<Universitas>
  <Nomor="160801">
    <Nama="Baskara">
      <Usia="18">
        <Prodi="Komunikasi">
          <Nomor="160802">
            <Nama="Alika">
              <Usia="20">
                <Prodi="Akuntansi">
                  ..... </Universitas>
```

```
package.json x
1  {
2    "name": "myapplication",
3    "description": "some description here",
4    "version": "0.0.1",
5    "private": true,
6    "scripts": {
7      "start": "node ./bin/www"
8    },
9    "dependencies": {
10     "express": "~4.12.2",
11     "jade": "~1.9.2"
12   }
13 }
```

Contoh data tidak terstruktur

- Data Teks
- Data gambar
- Data video
- Data Suara (audio)



Universitas ini memiliki 5600 mahasiswa. Baskara (Nomor mahasiswa: 160801), prodi komunikasi berusia 18 tahun. dengan nomor mahasiswa 160802, mengambil jurusan Teknik Informatika dan berusia 20 tahun.

Tasya dari prodi Psikologi, berusia 19 tahun nomor mahasiswa 160803.





Sumber-sumber dataset

1. Kaggle
2. UCI Machine Learning Repository
3. Satu Data Indonesia
4. Badan Pusat Statistik
5. Zdataset
6. data.gov
7. Google Dataset Search
8. Datahub.io
9. Global Health Observatory Data Repository
10. BFI Film Industry Statistics

Informasi dan Deskripsi Dataset

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   PassengerId  891 non-null    int64
1   Survived     891 non-null    int64
2   Pclass       891 non-null    int64
3   Name         891 non-null    object
4   Sex          891 non-null    object
5   Age          714 non-null    float64
6   SibSp        891 non-null    int64
7   Parch        891 non-null    int64
8   Ticket       891 non-null    object
9   Fare         891 non-null    float64
10  Cabin        204 non-null    object
11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

	Name	Sex	Ticket	Cabin	Embarked
count	891	891	891	204	889
unique	891	2	681	147	3
top	Braund, Mr. Owen Harris	male	347082	B96 B98	S
freq	1	577	7	4	644

```
1 import pandas as pd
2 import numpy as np
3
4 df = pd.read_csv("titanic.csv")
5 print(df.head())
6 print(df.info())
7 print(df.isnull().sum())
8 print(df.describe())
9 print(df.describe(exclude=np.number))
```




Data preprocessing

- Data preprocessing adalah suatu proses persiapan data mentah dan membuat data yang ada sesuai dengan model pembelajaran mesin.
- Preprocessing merupakan tahapan awal yang sangat krusial pada pembelajaran mesin.
- Data preprocessing sangat diperlukan pada Machine Learning karena dataset yang ada tidak selalu data yang bersih dan sudah sesuai format data. Sementara pada algoritma Machine Learning membutuhkan sudah **bersih** dan **format yang sesuai**.



Kenapa perlu Preprocessing

- Data real-world secara umum mengandung: noise, missing values, tidak memiliki format yang sesuai.
 - Data preprocessing berfungsi untuk membersihkan data dan membuat format yang sesuai dengan algoritma pembelajaran yang digunakan.
 - Data preprocessing dapat meningkatkan akurasi dan efisiensi pembentukan model.
- 



Tahapan Preprocessing

- Getting dataset
- Importing library
- Importing dataset
- Finding Missing value
- Encoding Categorical Data
- Splitting Dataset into training and test set
- Feature scaling

Preprocessing steps

- Get the Dataset
- Importing Libraries
- Importing the Datasets:
 - Extracting dependent
 - independent variables:
- Handling Missing data:
 - By deleting the particular row
 - By calculating the mean
- Encoding Categorical data
 - LabelEncoder
 - OneHotEncoder
- Splitting the Dataset (into the Training set and Test set)
- Feature Scaling




Missing value

- Hilang Sepenuhnya Secara Acak (MCAR, Missing Completely At Random)
- Hilang Secara Acak (MAR, Missing At Random)
- Hilang Tidak Secara Acak (MNAR, Missing Not At Random)



Teknik-teknik Penanganan Missing Value

- 1) Menghapus Data (Deletion Methods)
 - 2) Imputasi Sederhana (Simple Imputation)
 - 3) Constant Imputation
 - 4) Forward Fill dan Backward Fill
 - 5) Interpolation
- 

Menghapus Data (Deletion Methods)

- Listwise Deletion (menghapus baris)

Umur	Berat	Tinggi
20	60	170
25	NaN	165
30	70	175



Umur	Berat	Tinggi
20	60	170
30	70	175

- Column Deletion (menghapus kolom)

Umur	Berat	Tinggi
20	60	170
25	NaN	165
30	70	175



Umur	Tinggi
20	170
25	165
30	175

Imputasi Sederhana (Simple Imputation): Mengisi missing value dengan nilai statistik

- Mean Imputation (rata-rata): data numerik

$$x_{missing} = \frac{\sum x}{n}$$

Umur
20
25
NaN
35



$$x_{missing} = \frac{20 + 25 + 35}{3} = 26.6667$$



Umur
20
25
26,6667
35

Imputasi Sederhana (Simple Imputation): Mengisi missing value dengan nilai statistik

- Median Imputation: data numerik

Umur	Umur
20	20
25	25
NaN	
35	35

- X missing adalah 25

Umur	Umur
20	20
25	25
NaN	25
35	35

Imputasi Sederhana (Simple Imputation):

Mengisi missing value dengan nilai statistik

- Mode Imputation: data kategorikal

Warna	Warna
Merah	Merah
Biru	Biru
NaN	Biru
Biru	Biru

- X missing adalah Biru

Warna	Warna
Merah	Merah
Biru	Biru
NaN	Biru
Biru	Biru

Constant Imputation


- Mengisi nilai missing value dengan suatu nilai yang tetap.

Umur	Berat	Tinggi
20	60	170
25	NaN	165
30	70	175

- Dengan memberikan nilai tetap umur **60** maka:


Umur	Berat	Tinggi
20	60	170
25	60	165
30	70	175

Forward Fill dan Backward Fill: Digunakan pada data time series.



- **Forward Fill:** Mengisi dengan nilai sebelumnya


Umur	Berat	Tinggi
20	60	170
25	Nan	165
30	70	175



Umur	Berat	Tinggi
20	60	170
25	60	165
30	70	175

- **Backward Fill:** Mengisi dengan nilai berikutnya

Umur	Berat	Tinggi
20	60	170
25	Nan	165
30	70	175



Umur	Berat	Tinggi
20	60	170
25	70	165
30	70	175

Interpolasi:

Mengisi berdasarkan interpolasi matematis.

➤ linear interpolation:

x	y
1	10
2	20
3	NaN
4	40
5	50

$$y = y_1 + \frac{(x - x_1)}{(x_2 - x_1)} \times (y_2 - y_1)$$

$$y = 20 + \left(\frac{3 - 2}{4 - 2} \right) (40 - 20)$$

$$Y = 20 + \frac{1}{2} (20) = 20 + 10 = 30$$



x	y
1	10
2	20
3	30
4	40
5	50

Interpolasi K-NN:

Mengisi berdasarkan nilai tetangga terdekat.

No	Tinggi (cm)	Berat (kg)
1	150	50
2	155	55
3	160	NaN
4	165	65
5	170	70



No	Tinggi	Berat	Jarak
1	150	50	10
2	155	55	5
4	165	65	5
5	170	70	10

➤ Untuk $k = 2$

No	Tinggi (cm)	Berat (kg)
1	150	50
2	155	55
3	160	60
4	165	65
5	170	70

Untuk $k = 3$

No	Tinggi (cm)	Berat (kg)
1	150	50
2	155	55
3	160	56.67
4	165	65
5	170	70



Memperbaiki Missing Value

- Menghapus Keseluruhan Baris (Row)

```
#dropna function in Pandas removes all the rows with missing values  
data.dropna(inplace=True)
```

```
#Putting axis=1 removes the columns with missing values  
data.dropna(inplace=True, axis=1)
```

- Menghitung Nilai Pengganti (Imputation)



Tugas

- Tugas 3. Penanganan Data Missing Value
 - Tugas 4. Data Encoder Categorical
- 